

Projet de Statistique Inférentielle Avancée

Apport de la statistique inférentielle dans l'optimisation d'un classifieur SVM : Application au diagnostic médical

Master: Mathématiques et Ingénierie Numérique

Préparée par :
Doha Et-touimy

September 20, 2026

Encadré par :
M. Mourad el azhari

Introduction

Le cancer du sein constitue aujourd'hui un enjeu de santé publique majeur, nécessitant des outils de diagnostic de plus en plus précis.

L'objectif de ce travail est d'automatiser le processus de diagnostic médical en classifiant les tumeurs en deux catégories : malignes ou bénignes. Pour ce faire, nous avons mobilisé l'algorithme SVM (Support Vector Machines), reconnu pour son efficacité en classification.

L'intérêt central de cette étude est d'utiliser la statistique inférentielle comme passerelle, permettant de passer de l'analyse d'un échantillon de données à la réalité d'une population globale, afin d'assurer la validité scientifique et la généralisation des résultats obtenus.

- **Introduction et Modèle SVM**
- **Analyse Statistique des Données**
 - ▶ Échantillonnage et Description des Données
 - ▶ Analyse Exploratoire (Heatmap)
 - ▶ La Droite de Henry (Q-Q Plot)
- **Estimation et Inférence**
 - ▶ Estimation ponctuelle des paramètres (μ, σ)
 - ▶ Intervalle de Confiance du SVM
 - ▶ Maximum de Vraisemblance (MLE)
- **Validation Statistique du Modèle**
 - ▶ Test de Student d'Homogénéité
 - ▶ Test de Student de Conformité
 - ▶ Test d'hypothèse sur une proportion
 - ▶ Test du Khi-deux (χ^2) d'Adéquation
- **Conclusion**

Problématique

Comment l'inférence statistique peut-elle transformer le SVM d'un simple algorithme de calcul en un outil de diagnostic médical fiable et validé ?

Principe des SVM


Les SVM sont des algorithmes d'apprentissage supervisé utilisés pour la classification. Ils cherchent un hyperplan optimal qui sépare les classes avec une marge maximale afin d'assurer une bonne généralisation.

Définition de l'hyperplan

Les SVM cherchent à trouver un hyperplan optimal défini par :

$$w \cdot x + b = 0$$

où w est le vecteur normal et b le biais.



Fonction de décision

La classification d'une nouvelle donnée est donnée par :

$$y_{pred} = \text{sign}(w \cdot x + b)$$

Principe fondamental

Le SVM maximise la marge entre les classes, ce qui revient à minimiser $\|w\|^2$, avec :

$$\text{Marge} = \frac{2}{\|w\|}$$

Optimisation

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{sous la contrainte} \quad y_i(w \cdot x_i + b) \geq 1$$

Analyse Statistique des Données


Description des données

- **Source des données :** Base de données *Breast Cancer Wisconsin* (UCI Machine Learning Repository)
- **Taille de l'échantillon (n) :** 569 observations (patients)
- **Méthode d'échantillonnage :** Échantillonnage aléatoire simple (EAS)
- **30 variables explicatives quantitatives:** rayon, texture, aire, etc.
- **1 variable cible qualitative:** diagnostic (bénin / malin)

taille (569, 31)								
	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.30010	0.14710
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.08690	0.07060
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.19740	0.12730
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.24140	0.10130
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.19800	0.10430
5	12.45	15.70	82.57	477.1	0.12780	0.17000	0.15780	0.08000
6	18.25	19.98	119.60	1040.0	0.09463	0.10900	0.11270	0.07070
7	13.71	20.83	90.20	577.9	0.11890	0.16450	0.09366	0.05960
8	13.00	21.82	87.50	519.8	0.12730	0.19320	0.18590	0.09740

Analyse Exploratoire (Heatmap)

- une forte corrélation ($r \approx 1.00$) entre mean radius, mean perimeter et mean area, ce qui indique une redondance importante des informations et la présence de multicollinéarité.
- La forte corrélation entre variables justifie une réduction de dimension afin d'améliorer les performances du SVM et de limiter le surapprentissage.




Vérification de la Normalité : La Droite de Henry (Q-Q Plot)

- L'hypothèse de normalité est vérifiée à l'aide de la droite de Henry, dont l'équation est:

$$y = \frac{1}{\sigma}(x - \mu)$$

- Le fait que nos points expérimentaux s'alignent de manière quasi linéaire sur cette droite théorique montre que la distribution de la variable Mean Radius suit approximativement une loi normale.



Estimation et Inférence

Estimation ponctuelle des paramètres (μ , σ)

```
import numpy as np
from sklearn.datasets import load_breast_cancer

data = load_breast_cancer()
df = pd.DataFrame(data.data, columns=data.feature_names)

m_e = df['mean radius'].mean()

sigma_e = df['mean radius'].std(ddof=0)

sigma = df['mean radius'].std(ddof=1)

print(f"Moyenne observée (m_e): {m_e:.2f}")
print(f"Écart-type observé (sigma_e): {sigma_e:.2f}")
print(f"Écart-type estimé sans biais (sigma): {sigma:.2f}")

Moyenne observée (m_e): 14.13
Écart-type observé (sigma_e): 3.52
Écart-type estimé sans biais (sigma): 3.52
```

- La moyenne de l'échantillon est un estimateur sans biais de la moyenne de la population :

$$\hat{\mu} = \bar{x} = 14,13 \text{ mm}$$

- Estimation de l'écart-type (σ):

$$\sigma_e = 3,49 \text{ mm}$$
$$\hat{\sigma} = \sigma_e \sqrt{\frac{n}{n-1}} \approx 3,52 \text{ mm}$$

Intervalle de Confiance de la performance du SVM

```
model_svm = SVC(kernel='linear')
model_svm.fit(X_train_scaled, y_train)

y_pred = model_svm.predict(X_test_scaled)
f_accuracy = accuracy_score(y_test, y_pred)
n_test = len(y_test)

t_alpha = 1.96
erreur_standard = np.sqrt((f_accuracy * (1 - f_accuracy)) / n_test)
ic_inf = f_accuracy - (t_alpha * erreur_standard)
ic_sup = f_accuracy + (t_alpha * erreur_standard)

print(f"resultats")
print(f"Accuracy (f): {f_accuracy*100:.2f}%")
print(f"Intervalle de Confiance (95%): [{ic_inf*100:.2f}%, {ic_sup*100:.2f}%]")

resultats
Accuracy (f): 95.61%
Intervalle de Confiance (95%): [91.85% , 99.37%]
```

- Conditions de validité

$n = 114 \geq 30 \Rightarrow$ Application du Théorème Central Limitaire

- Formule de l'intervalle de confiance

$$IC = \left[f - t_{\alpha} \sqrt{\frac{f(1-f)}{n}} ; f + t_{\alpha} \sqrt{\frac{f(1-f)}{n}} \right]$$

Le Maximum de Vraisemblance (MLE) appliqué au SVM

```
results = pd.DataFrame({  
    'Distance (Géométrique)': distances,  
    'Probabilité Maligne (via MLE)': probs[:, 0],  
    'Probabilité Bénigne (via MLE)': probs[:, 1]  
})
```

```
print(results.to_string())
```

```
***
```

	Distance (Géométrique)	Probabilité Maligne (via MLE)	Probabilité Bénigne (via MLE)
0	1.004735	0.187662	0.812338
1	-7.606349	0.999683	0.000317
2	-4.249856	0.987051	0.012949
3	5.079704	0.002544	0.997456
4	6.407707	0.000001	0.999999

- Dans cette partie, les sorties du SVM sont transformées en probabilités comprises entre 0 et 1 à l'aide de la fonction sigmoïde :

$$\sigma(x) = \frac{1}{1 + e^{-(ax+b)}}$$

- Les paramètres a et b sont estimés grâce à la méthode du Maximum de Vraisemblance (MLE), ce qui permet de choisir les valeurs les plus adaptées aux données observées. Ainsi, on obtient une interprétation probabiliste des sorties du SVM utile en diagnostic médical.

Axe 3 : Test hypothèses I

Test de Student d'Homogénéité

Cadre Théorique & Hypothèses

Objectif : Déterminer si le *Mean Radius* permet de distinguer les classes Maligne (M) et Bénigne (B).

- $H_0 : \mu_M = \mu_B$ (le rayon moyen n'est pas discriminant)
- $H_1 : \mu_M \neq \mu_B$ (le rayon moyen est significatif)

Formulation Mathématique

$$t_{obs} = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{s_A^2/n_A + s_B^2/n_B}}$$

Règle de Décision

$$|t_{obs}| > t_{\alpha/2} \Rightarrow \text{Rejet de } H_0$$

Résultats du Test d'Homogénéité (Student)

Résultats du Test (Python)

- Statistique t_{obs} : 25.43
- p-value : 1.46×10^{-96} (0)

pour ($\alpha = 0.05$)

- Valeur critique : $t_{\alpha/2} = 1.96$
- Condition : $|t_{obs}| = 25.43 > 1.96$
- p-value : $1.46 \times 10^{-96} < 0.05$

Décision : Rejet de H_0 ce qui confirme que cette variable est fortement discriminante.

```
from scipy.stats import ttest_ind
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()
df = pd.DataFrame(data.data, columns=data.feature_names)
df['target'] = data.target # 0: Maligne, 1: Bénigne
group_M = df[df['target'] == 0]['mean radius']
group_B = df[df['target'] == 1]['mean radius']
t_obs, p_value = ttest_ind(group_M, group_B)
print(f"1. Statistique t (t_obs) : {t_obs:.4f}")
print(f"2. Test de Student (p-value) : {p_value:.10f}")
alpha = 0.05
if p_value < alpha:
    print(f"-> Décision : Rejet de H0 (p < {alpha})")
    print(f"-> Conclusion : Le rayon moyen est une variable SIGNIFICATIVE.")
else:
    print(f"-> Décision : Non-rejet de H0 (p >= {alpha})")
    print(f"-> Conclusion : Le rayon moyen n'est pas une variable significative.")

1. Statistique t (t_obs) : 25.4358
2. Test de Student (p-value) : 0.0000000000
-> Décision : Rejet de H0 (p < 0.05)
-> Conclusion : Le rayon moyen est une variable SIGNIFICATIVE.
```

Test de Student de Conformité

1. Cadre Théorique & Hypothèses

Objectif : Vérifier si la moyenne du *Mean Radius* est conforme à la norme médicale.

Norme : $\mu_0 = 14.0$

- $H_0 : \mu = 14.0$ (échantillon conforme à la norme)
- $H_1 : \mu \neq 14.0$ (écart significatif)

Formulation Mathématique

$$z_{obs} = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

Règle de Décision

$$|z_{obs}| > z_{\alpha/2} \Rightarrow \text{Rejet de } H_0$$

Résultats du Test de Conformité (Student)

Résultats du Test (Python)

- Moyenne observée : $\bar{x} = 14.1273$
- Valeur critique : $z_{\alpha/2} = 1.96$
- Statistique t_{obs} : 0.8616
- p-value : 0.3893

Conclusion : Non-rejet de H_0 donc notre échantillon est conforme aux standards médicaux.

```
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()
df = pd.DataFrame(data.data, columns=data.feature_names)
mu0 = 14.0
t_obs, p_value = ttest_1samp(df['mean radius'], popmean=mu0)
print(f"Norme de référence (mu0) : {mu0}")
print(f"Moyenne de l'échantillon : {df['mean radius'].mean():.4f}")
print(f"Statistique t (t_obs) : {t_obs:.4f}")
print(f"p-value : {p_value:.4f}")
alpha = 0.05
if p_value < alpha:
    print(f"-> Décision : Rejet de H0 (p < {alpha})")
    print("-> Conclusion : L'écart est significatif par rapport à la norme.")
else:
    print(f"-> Décision : Non-rejet de H0 (p >= {alpha})")
    print("-> Conclusion : L'échantillon est conforme à la norme médicale.")

Norme de référence (mu0) : 14.0
Moyenne de l'échantillon : 14.1273
Statistique t (t_obs) : 0.8616
p-value : 0.3893
-> Décision : Non-rejet de H0 (p >= 0.05)
-> Conclusion : L'échantillon est conforme à la norme médicale.
```

Test d'hypothèse sur une proportion

1. Cadre de l'étude & Hypothèses

Objectif : Vérifier si la précision du SVM dépasse le standard médical.

Standard : $p_0 = 0.90$

- $H_0 : p = 0.90$ (performance conforme)
- $H_1 : p > 0.90$ (performance supérieure)

Formulation Mathématique

$$z_{obs} = \frac{f - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

Règle de Décision

$$|z_{obs}| > z_{\alpha} \Rightarrow \text{Rejet de } H_0$$

Résultats du Test sur une Proportion (Z-test)

Résultats du Test (Python)

Paramètres :

- $f = 0.982$, $p_0 = 0.90$, $n = 114$

Résultats :

- $z_{obs} = 2.918$
- $z_{\alpha} = 1.645$
- $p\text{-value} = 0.0017$

Conclusion : Rejet de H_0 ce qui confirme la fiabilité du modèle.

```
import numpy as np
from scipy.stats import norm
f = 0.982
p0 = 0.90
n = 114
z_obs = (f - p0) / np.sqrt((p0 * (1 - p0)) / n)
p_value = 1 - norm.cdf(z_obs)
print(f"Statistique z (z_obs) : {z_obs:.4f}")
print(f"p-value : {p_value:.4f}")
if z_obs > 1.645:
    print("Décision : Rejet de H0 (Le modèle est supérieur

Statistique z (z_obs) : 2.9184
p-value : 0.0018
Décision : Rejet de H0 (Le modèle est supérieur au standard
```

Test du Khi-deux (χ^2) d'Adéquation

1. Cadre Théorique & Hypothèses

Objectif : Comparer la distribution des prédictions du SVM avec la réalité

- H_0 : Le modèle est adéquat (pas de différence significative)
- H_1 : Le modèle est inadéquat (différence significative)

Formulation Mathématique

$$\chi_{obs}^2 = \sum_{i=1}^k \frac{(O_i - T_i)^2}{T_i}$$

Règle de Décision

$$\chi_{obs}^2 > \chi_{1-\alpha}^2(\nu) \Rightarrow \text{Rejet de } H_0$$

Résultats du Test du Khi-deux (χ^2)

Résultats du Test (Python)

- $\chi^2_{obs} = 0.0373$
- $\chi^2_{critique} = 3.84$
- p-value = 0.8468

Décision & Conclusion

$$\chi^2_{obs} < \chi^2_{critique}$$

$$0.0373 < 3.84$$

$\Rightarrow$ Non-rejet de H_0

Le modèle SVM présente une bonne adéquation avec la distribution réelle des données


```
print(f"Effectifs prédits (Oj) : {obs_counts}")
print("-" * 50)
print(f"Statistique Khi2 (obs) : {chi2_obs:.4f}")
print(f"p-value : {p_value:.4f}")
alpha = 0.05
chi2_critique = 3.84
if chi2_obs > chi2_critique:
    print(f"\n-> Décision : Rejet de H0 (Car {chi2_obs:.3f} > {chi2_critique})")
    print("-> Conclusion : Le modèle est INADÉQUAT (différence significative).")
else:
    print(f"\n-> Décision : Non-rejet de H0 (Car {chi2_obs:.3f} <= {chi2_critique})")
    print("-> Conclusion : Le modèle est ADÉQUAT (bonne adéquation).")

===== AXE 3 : TEST DU KHI-DEUX D'ADÉQUATION =====
Effectifs réels (Ti) : [43 71]
Effectifs prédits (Oj) : [44 70]
-----
Statistique Khi2 (obs) : 0.0373
p-value : 0.8468

-> Décision : Non-rejet de H0 (Car 0.037 <= 3.84)
-> Conclusion : Le modèle est ADÉQUAT (bonne adéquation).
```

Visualisation de la séparation des classes

Frontière de Décision du Classifieur SVM (Visualisation 2D via PCA)



Conclusion

En conclusion, cette étude a montré que la performance d'un modèle Support Vector Machine en diagnostic médical doit être validée par la statistique inférentielle. L'utilisation du Maximum de Vraisemblance (MLE) a permis une interprétation probabiliste des résultats, tandis que les tests statistiques (Student, Z-test et Khi-deux) ont confirmé la significativité et la fiabilité du modèle. Avec une précision de 98,2 , le SVM démontre une forte capacité de généralisation et constitue ainsi un outil de diagnostic robuste et scientifiquement fiable.